



M&M

INTELIGENCIA ARTIFICIAL
INNOVACIONES

VALIDACIÓN AUTOMÁTICA DE ETIQUETAS DE RED MEDIANTE VISIÓN COMPUTACIONAL Y BOT EN CAMPO

María Augusta Flores | Marcelo Andrade
www.acclatam.lat/mmia



Validación automática de etiquetas de red mediante visión computacional y Bot en campo

Diagnóstico de Overfitting/Underfitting



Institución: UEES

Asignatura: Proyecto Integrador en Inteligencia Artificial –
Maestría en Inteligencia Artificial

Docente: Ing. Gladys Villegas Rugel

Guayaquil – septiembre 2025

Quito, Ecuador. Telf. (593) 095 861 0558 / 098 270 4137

E-mail: info@acclatam.lat
www.acclatam.lat/mmia





Tabla de Contenidos

Validación automática de etiquetas de red mediante visión computacional y Bot en campo	2
Tabla de Contenidos	1
1. Resumen Ejecutivo	2
2. Metodología Utilizada	3
3. Resultados del Diagnóstico	3
4. Análisis de Curvas de Aprendizaje	3
5. Estrategias Implementadas y Resultados	5
6. Conclusiones y Recomendaciones Futuras	6
7. Referencias Técnicas	6





1. Resumen Ejecutivo

Este informe presenta el diagnóstico exhaustivo del comportamiento de un modelo de clasificación binaria aplicado a un problema real del ámbito de telecomunicaciones, específicamente al control de calidad de etiquetas físicas utilizadas en cajas MPLS. El propósito central fue identificar si el modelo entrenado presentaba problemas típicos de generalización, como el sobreajuste (overfitting) o infraajuste (underfitting), o si se encontraba en un punto óptimo de rendimiento.

Para ello, se aplicó una metodología estructurada que incluyó carga y exploración de datos, preprocesamiento con codificación categórica, entrenamiento con un modelo de Random Forest, implementación de un sistema de tracking de métricas durante el entrenamiento, y la generación de curvas de aprendizaje profesionales.

El análisis visual, combinado con métricas cuantitativas clave (accuracy, precision, recall, F1-score), permitió un diagnóstico confiable del modelo. Se detectó un leve "gap" entre entrenamiento y validación, que no representaba síntomas de sobreajuste grave. Adicionalmente, se implementaron dos estrategias de mejora: aumento de complejidad (número de árboles) y regularización (limitación de la profundidad máxima), lo que resultó en un modelo mejorado con mejor generalización.

El modelo final presentó una precisión superior al 91% y una puntuación F1 por encima del 91%, demostrando robustez frente a datos nuevos. Este resultado valida tanto la elección del algoritmo como las decisiones metodológicas adoptadas.

En conclusión, el trabajo evidencia la importancia del diagnóstico temprano de problemas de aprendizaje en modelos de IA y sienta las bases para futuras mejoras basadas en técnicas avanzadas, como validación cruzada, optimización de hiperparámetros y uso de modelos más complejos en caso de escalar a otros dominios como imágenes o video.





2. Metodología Utilizada

Se trabajó con un dataset tabular real que contiene variables como `color\_buffer` (color de la etiqueta) y `tipo\_ruta`, junto con una columna binaria `clase` como variable objetivo.

El proceso seguido fue:

- Carga y exploración del dataset (818 registros)
- Codificación One-Hot para variables categóricas
- División estratificada 80/20 en entrenamiento y validación
- Entrenamiento con RandomForestClassifier (modelo base)
- Implementación de sistema de tracking modular para registrar métricas
- Visualización de curvas de aprendizaje (`learning\_curve`) y validación (`validation\_curve`)
- Diagnóstico técnico (gap, comportamiento de loss y accuracy)
- Aplicación de estrategias de mejora (regularización y complejidad)

3. Resultados del Diagnóstico

El modelo base alcanzó un rendimiento balanceado: Accuracy $\approx$ 89%, Precision $\approx$ 91%, Recall $\approx$ 87%, y F1-Score $\approx$ 89%.

El diagnóstico mostró un pequeño gap entre entrenamiento y validación, lo que indica un modelo bien ajustado con margen de mejora.


No se observaron síntomas claros de overfitting (pérdida en validación creciente) ni de underfitting (bajo rendimiento en ambas fases).

4. Análisis de Curvas de Aprendizaje


Se generaron tres gráficos clave a partir del entrenamiento con Scikit-learn:

Learning Curve – Accuracy vs Training Set Size: mostró una evolución estable con leve separación entre entrenamiento y validación.






Learning Curve – Simulated Loss: se utilizó $\text{loss} = 1 - \text{accuracy}$ para simular la pérdida, evidenciando una disminución sin señales de sobreajuste.





Validation Curve – max_depth: ayudó a determinar el rango óptimo de profundidad para los árboles de decisión, mostrando sobreajuste leve en valores altos.



5. Estrategias Implementadas y Resultados

Se aplicaron dos estrategias clave para mejorar el rendimiento del modelo:

- 1. Aumento de complejidad:** incremento de `n\_estimators` de 100 a 300, lo que permitió un aprendizaje más robusto.
- 2. Regularización:** fijación de `max\_depth=5` para evitar que los árboles crezcan demasiado y memoricen ruido.

Como resultado, el modelo mejorado obtuvo:

- Accuracy $\approx$ 91%
- Precision $\approx$ 93%
- Recall $\approx$ 90%
- F1-Score $\approx$ 91%

Se observó una mejora generalizada en todas las métricas, además de un gap más controlado.





6. Conclusiones y Recomendaciones Futuras

El análisis confirmó que el modelo base era adecuado, y que con mejoras específicas se logró un desempeño aún más robusto.

El uso de técnicas visuales, métricas de evaluación y estrategias de ajuste permitió realizar un diagnóstico preciso.

Se recomienda para trabajos futuros:

- Incluir más variables predictoras (e.g. ubicación, tipo de nodo)
- Evaluar clasificadores adicionales (SVM, XGBoost)
- Implementar validación cruzada más estricta (k-fold)
- Escalar a modelos de visión computacional si se usan imágenes directamente

7. Referencias Técnicas

- Scikit-learn Documentation: <https://scikit-learn.org/stable/>
- Géron, A. (2019). Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow. O'Reilly Media.
- Bishop, C. M. (2006). Pattern Recognition and Machine Learning.
- Documentación oficial de Pandas, Matplotlib y NumPy.

