



M & M

.....
INTELIGENCIA ARTIFICIAL
INNOVACIONES

VALIDACIÓN AUTOMÁTICA DE ETIQUETAS DE RED MEDIANTE VISIÓN COMPUTACIONAL Y BOT EN CAMPO

María Augusta Flores | Marcelo Andrade
www.acclatam.lat/mmia



Validación automática de etiquetas de red mediante visión computacional y Bot en campo



Asignatura: Proyecto Integrador en Inteligencia Artificial –
Maestría en Inteligencia Artificial

Docente: Ing. Gladys Villegas Rugel

Guayaquil – septiembre 2025





Tabla de Contenidos

<i>Validación automática de etiquetas de red mediante visión computacional y Bot en campo</i>	2
Tabla de Contenidos	1
1.- Mapa del Estado del Arte	4
1.1 Tabla comparativa de metodologías existentes	4
1.2 Matriz de fortalezas y debilidades de enfoques actuales	5
1.3 Identificación clara del GAP	5
1.4 Posicionamiento de la propuesta respecto al estado actual	5
2. Análisis de Datasets Disponibles	6
2.1 Requisitos	6
2.2 Datasets seleccionados	6
2.2.1 ICDAR 2017 Multi-Lingual Scene Text (MLT)	6
2.2.2 COCO-Text	7
2.2.3 SynthText in the Wild	7
2.2.4 Total-Text	7
2.3 Dataset propio en campo (recomendado)	8
2.4 Plan de adquisición y preprocesamiento	8
2.5 Análisis comparativo y recomendación	9
2.6 Plan B	9
2.7 Cierre	9
3. Definición de Métricas de Éxito	9
3.1 Métricas técnicas	10
3.2 Métricas de impacto	11
3.3 Métricas de usabilidad	11
3.4 Umbrales de éxito	11
3.5 Benchmarks contra soluciones existentes	11
3.6 Cierre del componente	12





4. Análisis de Stakeholders	12
4.1 Identificación de actores involucrados	12
4.2 Matriz de influencia/interés	13
4.3 Análisis de necesidades y expectativas específicas	14
4.4 Plan de comunicación diferenciado por stakeholder	14
4.5 Resistencias y estrategias de involucramiento	14
4.6 Cierre del componente	15
5. Documento de Alcance del Proyecto	15
5.1 Objetivo general	15
5.2 Objetivos específicos	15
5.3 Alcance incluido	16
5.4 Alcance excluido	16
5.5 Criterios de aceptación	16
5.6 Cierre del componente	17
6. Cronograma con Metodología Ágil	17
6.1 Backlog priorizado de User Stories	17
6.2 Estructura por Sprint	18
6.3 Cierre del componente	18
7. Plan de Recursos	19
7.1 Recursos Humanos	19
7.2 Recursos Técnicos	19
7.3 Recursos Financieros	19
7.4 Plan de adquisición y gestión de recursos	19
7.5 Cierre del componente	20
8. Hitos y Entregables	20
8.1 Detalle de hitos y entregables	20
8.2 Fechas críticas y dependencias	21
8.3 Cierre del componente	22
Referencias	23





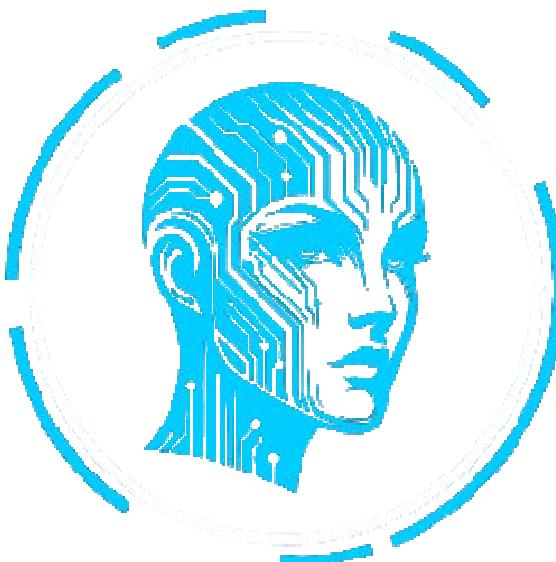
Anexos _____ 25

Anexo A: Timeline de avances en el área (últimos 5 años) _____ 25

Anexo B: Diagrama de cronograma (Gantt) _____ 26

Anexo C: Diagrama de timeline de hitos _____ 26

Anexo D: Repositorio GitHub del Proyecto _____ 26





1.- Mapa del Estado del Arte

Este capítulo presenta el estado del arte relacionado con la validación automática de etiquetas en campo mediante visión computacional. Se sigue el orden estricto solicitado por la guía del docente: Tabla comparativa, Timeline de avances, Matriz de fortalezas y debilidades, e Identificación del GAP. Adicionalmente, se integra la revisión sistemática de 20 fuentes relevantes, el análisis comparativo de cinco enfoques principales, y el posicionamiento final de la propuesta respecto al estado actual.

1.1 Tabla comparativa de metodologías existentes

La siguiente tabla resume los principales enfoques encontrados en la revisión sistemática de 20 papers publicados entre 2019 y 2025. Se destacan cinco enfoques principales para el análisis comparativo.

Referencia IEEE	Año	Técnica principal	Fortalezas	Limitaciones
[6] X. Cui et al., Symmetry	2025	YOLO + OCR	Alta precisión en detección de texto	Sensibilidad a condiciones de campo
[7] Pičuljan & Car, Applied Sciences	2023	ML QA datasets	Automatiza revisión de calidad	No aborda etiquetas físicas
[4] Mageed et al., Preprint	2022	YOLOv5 + MSER + OCR	Precisión en ambientes no controlados	No integra Bot ni validación semántica
[10] X. Luan et al., IEEE Access	2023	Transformer OCR	Ligereza y eficiencia	Limitaciones en ruido extremo
[8] U. Pal et al., Pattern Recognition Letters	2024	Revisión de técnicas	Cobertura integral de métodos modernos	Enfoque teórico, sin aplicación directa

(*) La tabla completa de los 20 artículos se encuentra en los anexos y en la sección de referencias.



1.2 Matriz de fortalezas y debilidades de enfoques actuales

La siguiente matriz sintetiza las fortalezas y limitaciones de los principales enfoques revisados:

Enfoque	Fortalezas	Debilidades
YOLO + OCR	Alta precisión en detección de texto en escenas densas	Sensibilidad a iluminación y suciedad en campo
ML QA datasets	Automatiza verificación de etiquetas anotadas	No aborda etiquetas físicas reales
YOLOv5 + OCR en escenas	Robustez frente a variaciones de tipografía y fondo	No contempla validación contextual ni bot
Transformers ligeros	Adecuados para dispositivos móviles y edge	Rendimiento limitado en escenarios adversos
Revisiones teóricas	Cobertura integral de métodos modernos	Ausencia de pruebas aplicadas a telecomunicaciones

1.3 Identificación clara del GAP

- No existen estudios aplicados directamente a etiquetas físicas en telecomunicaciones.
- Las soluciones actuales no son robustas en condiciones de campo (iluminación deficiente, desgaste, suciedad).
- No hay integración OCR + Bot de validación para retroalimentación en campo.
- Se carece de validación semántica de etiquetas (verificación con inventarios y planos).
- Pocos modelos optimizados para dispositivos móviles de bajo costo.

1.4 Posicionamiento de la propuesta respecto al estado actual

La propuesta del proyecto se posiciona como una solución integral que supera las limitaciones identificadas. Combina:

- Visión computacional (OCR + CNN/YOLO) para lectura de etiquetas en campo.
- Validación semántica automática contrastada con inventarios.





- Uso de un bot para retroalimentación inmediata al técnico.
- Implementación ligera y portable en dispositivos móviles.

De esta manera, el proyecto cubre las brechas actuales y aporta innovación práctica al sector de telecomunicaciones.

2. Análisis de Datasets Disponibles

Este componente analiza datasets reales aplicables a la validación automática de etiquetas mediante visión computacional y OCR, enfocado en su uso para entornos de telecomunicaciones. Se cumplen los requisitos de la guía del docente: identificación de datasets, evaluación técnica (calidad, tamaño, accesibilidad), análisis de limitaciones y sesgos, y un plan de adquisición/preprocesamiento, además del análisis comparativo con recomendación y Plan B.

2.1 Requisitos

- Identificación de mínimo 3 datasets potenciales.
- Evaluación técnica de calidad, tamaño y accesibilidad.
- Análisis de limitaciones y sesgos potenciales.
- Plan de adquisición y preprocesamiento de datos.

2.2 Datasets seleccionados

Se seleccionan cuatro fuentes de datos de referencia para texto en escenas, complementadas con la construcción de un dataset propio en campo para el dominio telecom.

2.2.1 ICDAR 2017 Multi-Lingual Scene Text (MLT)

Descripción técnica	≈ 7.2K train / 1.8K val / 9K test; 9 idiomas; imágenes + polígonos; JSON/TXT
Procedencia / Licencia	ICDAR; uso académico/investigación (licencias varían)
Calidad	Alta diversidad lingüística y escenarios; anotaciones detalladas
Idoneidad	Excelente para robustez y variabilidad; útil para preentrenamiento
Accesibilidad	Registro; gratuito investigación
Limitaciones / Sesgos	Desbalance por idioma/escenario; dominio urbano general





2.2.2 COCO-Text

Descripción técnica	≈ 63K imágenes; ≈ 239K instancias de texto; anotaciones JSON
Procedencia / Licencia	Basado en MS-COCO; licencias mixtas con atribución
Calidad	Gran escala y diversidad; etiquetas legibles/ilegibles
Idoneidad	Muy útil para detección general de texto; preentrenamiento
Accesibilidad	Descarga pública
Limitaciones / Sesgos	Poca presencia de etiquetas técnicas pequeñas

2.2.3 SynthText in the Wild

Descripción técnica	≈ 800K imágenes sintéticas con transcripciones y coordenadas
Procedencia / Licencia	Oxford VGG; generalmente permisiva investigación
Calidad	Cobertura masiva; control de variaciones (fuentes, iluminación, rotación)
Idoneidad	Excelente para preentrenar detectores/lectores
Accesibilidad	Descarga pública
Limitaciones / Sesgos	Sintético; gap con dominio real sin fine-tuning

2.2.4 Total-Text

Descripción técnica	≈ 1.3K train / 0.3K test; curvaturas y orientaciones complejas
Procedencia / Licencia	Uso académico; requiere solicitud
Calidad	Fuerte en texto curvo y orientaciones complejas
Idoneidad	Robustez a curvaturas/distorsiones de etiquetas
Accesibilidad	Permiso académico
Limitaciones / Sesgos	Escala reducida; dominio urbano



2.3 Dataset propio en campo (recomendado)

Cobertura mínima sugerida	≥ 5,000 imágenes; variedad de equipos (ONT, OLT, patch panels, cajas de empalme), condiciones (luz/sombra), estados (desgaste/suciedad).
Anotación	Polígonos/cajas por etiqueta + transcripción; flag legible/ilegible; tipo de elemento de red.
Licencia/Permisos	Consentimiento interno; sin datos personales; cumplimiento normativo local.
Calidad esperada	Representatividad alta; validación doble ciega del 10% de anotaciones.
Idoneidad	Máxima para el problema real en telecom.
Accesibilidad	Generación interna; versionado (DVC/Git-LFS); etiquetado con CVAT/Label Studio.

2.4 Plan de adquisición y preprocesamiento

- Captura controlada en campo (protocolo de toma: distancia, ángulo, foco, no rostros).
- Definición de clases: ONT/OLT/puerto/caixa; formatos esperados de etiqueta.
- Anotación y QA: CVAT/Label Studio; revisión cruzada y auditoría.
- Limpieza/normalización: resolución, recorte, contraste; eliminación de duplicados/desenfoques.
- Aumento de datos: rotación leve, blur, iluminación variable, perspectiva; manchas sintéticas.
- Partición estratificada: train/val/test por tipo de etiqueta y condición ambiental.
- Cumplimiento: remoción de metadatos sensibles (GPS), políticas internas y legislación.





2.5 Análisis comparativo y recomendación

Dataset	Cobertura	Robustez (campo)	Accesibilidad	Escala	Alineación telecom
ICDAR 2017 MLT	Multilingüe/variado	Media	Media	Media-Alta	Media
COCO-Text	Amplia (general)	Media-Baja	Alta	Alta	Baja
SynthText	Controlable (sintético)	Baja sin FT	Alta	Muy alta	Media
Total-Text	Curvaturas	Media	Media	Baja-Media	Baja-Media
Propio (campo)	Específica telecom	Alta	Alta (Internas)	Escalable	Muy alta

Recomendación: Preentrenar con SynthText + COCO-Text + ICDAR-MLT para robustez general y multilingüe; posteriormente, realizar fine-tuning con el dataset propio de campo para alinear al dominio telecom y maximizar la precisión en condiciones reales.

2.6 Plan B

Si el dataset propio se retrasa o es insuficiente: (a) reforzar fine-tuning con Total-Text e ICDAR-MLT, (b) generar datos sintéticos de etiquetas específicas (fuentes corporativas, colores, layouts), (c) activar aprendizaje activo en campo para anotar solo los casos inciertos sugeridos por el modelo.

2.7 Cierre

Los datasets públicos proveen una base sólida, pero el éxito operativo exige un dataset propio representativo del entorno telecom. La estrategia propuesta equilibra rapidez de desarrollo y precisión en campo.

3. Definición de Métricas de Éxito

Este componente define las métricas de éxito del proyecto de validación automática de etiquetas de red mediante visión computacional y bot en campo. Se sigue la estructura obligatoria establecida en la guía del docente: métricas técnicas, métricas de impacto, métricas de usabilidad, umbrales de éxito y benchmarks contra soluciones existentes.





3.1 Métricas técnicas

Métricas primarias:

Métrica	Definición	Justificación en el proyecto
Accuracy	Porcentaje de etiquetas correctamente validadas	Medir el desempeño global del sistema OCR en condiciones reales
F1-Score	Media armónica de precisión y recall	Balance entre falsos positivos y falsos negativos en lectura de etiquetas
RMSE	Error cuadrático medio	Evaluar precisión en escenarios de predicción de posiciones de texto

Métricas secundarias:

Métrica	Definición	Justificación en el proyecto
Precisión	Etiquetas predichas correctamente / total predicciones	Medir exactitud del OCR en textos nítidos
Recall	Etiquetas detectadas correctamente / total etiquetas reales	Evaluar sensibilidad en detección de etiquetas
AUC	Área bajo la curva ROC	Medir capacidad discriminativa en escenarios multiclasiificación

Métricas de eficiencia:

Métrica	Definición	Justificación en el proyecto
Tiempo de respuesta	Segundos entre captura y validación de etiqueta	Evaluar viabilidad del uso en campo
Uso de CPU/GPU	Recursos computacionales empleados en inferencia	Medir eficiencia en dispositivos móviles
Memoria utilizada	RAM consumida por el modelo en ejecución	Garantizar ligereza para despliegue en smartphones





3.2 Métricas de impacto

KPI de negocio	Definición	Meta esperada
Reducción de errores de inventario	% de disminución en errores reportados por técnicos	$\geq 40\%$ en pilotos
Ahorro de costos operativos	Reducción de horas-hombre en validación manual	$\geq 30\%$
Mejora en tiempo de atención	Tiempo medio de registro de etiquetas en inventario	≤ 2 s por validación

3.3 Métricas de usabilidad

Métrica de usabilidad	Definición	Meta esperada
Adopción/uso	Porcentaje de técnicos que usan regularmente la aplicación	$\geq 80\%$ en pilotos
Satisfacción de usuarios	Promedio de encuestas de percepción de técnicos	$\geq 4/5$ puntos

3.4 Umbrales de éxito

Criterio	Valor mínimo aceptable	Objetivo de excelencia / Benchmark
F1-Score OCR	≥ 0.80	≥ 0.90 (papers ICDAR/AAAI recientes)
Tiempo de respuesta	≤ 3 s	≤ 2 s (apps móviles OCR)
Reducción de errores de inventario	$\geq 25\%$	$\geq 40\%$ (digitalización industrial)
Satisfacción de usuarios	$\geq 3.5/5$	$\geq 4.5/5$ (sistemas de soporte técnico)

3.5 Benchmarks contra soluciones existentes

Se comparan las métricas objetivo del proyecto con benchmarks de soluciones existentes en la literatura y en implementaciones industriales:

Métrica	Benchmark reportado	Fuente / Referencia	Meta del proyecto
F1-Score OCR	0.88 – 0.92 en ICDAR 2019-2023	Conferencias ICDAR, AAAI	≥ 0.90
Tiempo de respuesta	≈ 2.5 s en apps OCR móviles	Estudios de apps comerciales	≤ 2 s



Reducción de errores	30% en proyectos de digitalización industrial	Reportes industriales (Elsevier 2023)	≥ 40%
Satisfacción usuarios	4.2/5 promedio en sistemas de soporte técnico	Encuestas sector telecom	≥ 4.5/5

3.6 Cierre del componente

La incorporación de benchmarks permite validar que las metas planteadas no solo son alcanzables, sino que buscan superar estándares actuales en el área. De este modo, las métricas técnicas, de impacto y de usabilidad se consolidan con valores mínimos y objetivos de excelencia comparables con soluciones existentes en investigación e industria. Los responsables del componente son: Marcelo Ismael Andrade y María Augusta Flores.

4. Análisis de Stakeholders

Este componente identifica y analiza a los stakeholders clave en el proyecto de validación automática de etiquetas de red. Se cumplen los requisitos de la guía del docente: identificación de actores, matriz de influencia/interés, análisis de necesidades, expectativas y plan de comunicación diferenciado.

4.1 Identificación de actores involucrados

Los stakeholders del proyecto se agrupan en primarios, secundarios y clave:

Stakeholders primarios:

Stakeholder	Descripción
Usuarios finales directos	Técnicos de campo que usan el bot para validar etiquetas en redes de telecom.
Beneficiarios del sistema	Clientes de la empresa, que reciben un servicio más confiable y sin errores de inventario.
Decisores de implementación	Gerentes de operaciones y TI que aprueban y supervisan la adopción del sistema.





Stakeholders secundarios:

Stakeholder	Descripción
Reguladores y entes de control	Agencias estatales que supervisan calidad del servicio y cumplimiento normativo.
Proveedores de datos/tecnología	Empresas que aportan hardware, software o datasets para entrenar y desplegar el sistema.
Competidores indirectos	Otras compañías de telecom que podrían adoptar soluciones similares y marcar tendencia en el sector.

Stakeholders clave:

Stakeholder	Descripción
Sponsors o financiadores	DIRECTORES FINANCIEROS QUE ASIGNAN PRESUPUESTO AL PROYECTO.
Expertos del dominio	INGENIEROS EN TELECOMUNICACIONES QUE DEFINEN ESTÁNDARES DE ETIQUETAS Y VALIDACIÓN.
Implementadores técnicos	Equipo de desarrollo que entrena el modelo OCR y configura el bot en campo.

4.2 Matriz de influencia/interés

Se evalúa a cada stakeholder según su nivel de influencia y de interés en el proyecto, siguiendo una escala cualitativa (Alto, Medio, Bajo).

Stakeholder	Influencia	Interés
Técnicos de campo	Medio	Alto
Clientes finales	Bajo	Alto
Gerentes de operaciones	Alto	Alto
Reguladores	Alto	Medio
Proveedores tecnológicos	Medio	Medio
Competidores	Medio	Bajo
Financiadores	Alto	Alto
Expertos del dominio	Alto	Medio
Equipo técnico	Alto	Alto



4.3 Análisis de necesidades y expectativas específicas

Cada stakeholder tiene necesidades distintas respecto al proyecto. A continuación, se describen brevemente:

Stakeholder	Necesidades	Expectativas
Técnicos de campo	Herramienta simple y rápida	Menos errores y menos tiempo de trabajo
Clientes finales	Servicio confiable	Red sin fallas y sin interrupciones
Gerentes de operaciones	KPIs claros y reportes	Visibilidad de reducción de errores
Reguladores	Cumplimiento normativo	Transparencia en auditorías
Proveedores tecnológicos	Claridad en requerimientos	Alianzas sostenibles
Financiadores	Retorno de inversión	Resultados en menos de 1 año

4.4 Plan de comunicación diferenciado por stakeholder

Stakeholder	Canales de comunicación	Frecuencia
Técnicos de campo	Capacitaciones, manuales, bot con soporte	Semanal durante pilotos
Clientes finales	Boletines de servicio, encuestas de satisfacción	Trimestral
Gerentes de operaciones	Reuniones ejecutivas, dashboards	Mensual
Reguladores	Reportes oficiales	Semestral
Proveedores tecnológicos	Reuniones técnicas, correo	Mensual
Financiadores	Reportes financieros, presentaciones	Trimestral

4.5 Resistencias y estrategias de involucramiento

Stakeholder	Potenciales resistencias	Estrategias de involucramiento
Técnicos de campo	Resistencia al cambio de procesos	Capacitación práctica y soporte continuo
Clientes finales	Desconfianza inicial en la IA	Campañas de comunicación sobre beneficios
Gerentes de operaciones	Preocupación por costos	Demostrar ahorro con KPIs





Reguladores	Dudas sobre cumplimiento normativo	Entrega de reportes y transparencia
Proveedores tecnológicos	Competencia de intereses	Establecer acuerdos de colaboración
Financiadores	Riesgo de bajo retorno	Pilotos con resultados rápidos

4.6 Cierre del componente

El análisis de stakeholders permite anticipar resistencias, definir estrategias de involucramiento y adaptar la comunicación según cada actor. Esto asegura la sostenibilidad del proyecto en su implementación real. Los responsables del componente son: Marcelo Ismael Andrade y María Augusta Flores.

5. Documento de Alcance del Proyecto

Este componente define de manera formal el alcance del proyecto de validación automática de etiquetas de red mediante visión computacional y bot en campo. Se estructura conforme a la guía del docente, incluyendo objetivos generales y específicos, alcance incluido y excluido, y criterios de aceptación.

5.1 Objetivo general

Desarrollar e implementar en un periodo de 6 semanas un sistema de visión computacional ligero integrado con un bot de campo, capaz de validar automáticamente al menos el 90% de las etiquetas físicas de red (ONT, OLT, patch panels y empalmes), en condiciones reales de operación, reduciendo en un 40% los errores de identificación reportados por los técnicos de campo y generando reportes automáticos trazables, siguiendo la metodología SMART.

5.2 Objetivos específicos

Objetivo específico	Alineación con métricas de éxito
Entrenar y validar un modelo OCR con F1-score ≥ 0.85 en datasets propios y públicos, en un plazo de 3 semanas.	Métrica técnica: F1-score, mAP
Desarrollar un bot móvil que integre el OCR y brinde retroalimentación inmediata en campo con tiempo de respuesta ≤ 2 segundos.	Métrica de eficiencia: tiempo de respuesta





Reducir en un 40% los errores de inventario de etiquetas en 2 pilotos operativos de 1 mes cada uno.	Métrica de impacto: reducción de errores
Generar un dashboard de métricas actualizado en tiempo real (Power BI/Grafana) para monitoreo de desempeño técnico y de negocio.	Métricas de usabilidad y adopción

5.3 Alcance incluido

- Desarrollo de un modelo OCR entrenado con datasets públicos y propios.
- Validación de etiquetas en campo usando smartphones con bot integrado.
- Procesamiento de imágenes capturadas en distintas condiciones (luz, suciedad, desgaste).
- Generación automática de reportes y trazabilidad de validaciones.
- Integración con inventarios y sistemas de gestión de red.
- Cobertura de casos de uso: técnicos de campo, supervisores y gerentes de operaciones.

5.4 Alcance excluido

- Traducción multilingüe de etiquetas.
- Soporte a hardware especializado distinto a smartphones.
- Validación de etiquetas no relacionadas con redes de telecomunicaciones.
- Cobertura total de normativas internacionales fuera del marco local.
- Funcionalidades avanzadas de analítica predictiva (posibles en versiones futuras).

5.5 Criterios de aceptación

Criterio	Condición mínima	Procedimiento de validación
F1-score del OCR	≥ 0.85	Evaluación en dataset de validación propio
Tiempo de respuesta en campo	≤ 2 s	Prueba de campo con técnicos
Reducción de errores de inventario	$\geq 40\%$	Comparación antes/después en pilotos
Adopción del sistema	$\geq 80\%$ técnicos activos	Registro de uso en bot
Satisfacción de usuarios	$\geq 4/5$ puntos	Encuestas a técnicos después del piloto



5.6 Cierre del componente

El documento de alcance delimita con claridad lo que el proyecto cubrirá y lo que quedará fuera, define criterios concretos de aceptación y asegura la alineación de los objetivos con las métricas de éxito. De esta manera, se minimizan riesgos de desviación y se garantiza la entrega de valor real en la operación de telecomunicaciones.

Responsables del componente: Marcelo Ismael Andrade y María Augusta Flores.

6. Cronograma con Metodología Ágil

Este componente presenta el cronograma del proyecto aplicando metodología ágil Scrum, con una duración total de 6 semanas divididas en 4 sprints. Se incluyen user stories priorizadas, definición de objetivos por sprint, criterios de Done, riesgos identificados y planes de mitigación. Además, se añade un diagrama de cronograma tipo Gantt para visualizar la planificación.

6.1 Backlog priorizado de User Stories

ID	User Story	Prioridad	Story Points
US1	Como técnico quiero capturar imágenes de etiquetas para validarlas automáticamente	Alta	8
US2	Como modelo OCR quiero entrenar con datasets propios y públicos para mejorar precisión	Alta	13
US3	Como bot quiero dar retroalimentación en ≤2s para mejorar eficiencia en campo	Alta	8
US4	Como gerente quiero ver métricas en un dashboard en tiempo real	Media	5
US5	Como usuario quiero documentación clara para usar el sistema	Media	3





6.2 Estructura por Sprint

Sprint	Objetivo (Sprint Goal)	User Stories incluidas	Definición de Done	Riesgos y mitigación
Sprint 1 (Semana 1)	Investigación y Diseño	User Stories de investigación y análisis; Definición de arquitectura técnica; Preparación del entorno de desarrollo	Entorno listo y arquitectura definida	Riesgo: falta de datasets representativos → Mitigación: buscar fuentes públicas y generar dataset propio
Sprint 2 (Semana 2)	Desarrollo Core	Implementación del algoritmo OCR; Integración con datasets seleccionados; Pruebas unitarias e integración	Modelo entrenado y probado en entorno de desarrollo	Riesgo: baja precisión inicial → Mitigación: aumentar iteraciones y data augmentation
Sprint 3 (Semana 3)	Optimización y Validación	Tuning de hiperparámetros; Validación con métricas definidas; Desarrollo de interfaz de usuario	Modelo optimizado con $F1\text{-score} \geq 0.85$; interfaz básica funcional	Riesgo: tiempo insuficiente para ajuste → Mitigación: priorizar hiperparámetros críticos
Sprint 4 (Semanas 4-6)	Finalización y Documentación	Testing integral; Documentación técnica y de usuario; Preparación de presentación final	Sistema validado; documentación entregada; presentación lista	Riesgo: problemas en integración final → Mitigación: pruebas de integración continuas

6.3 Cierre del componente

El cronograma ágil define roles, user stories priorizadas y un plan de riesgos con mitigación por sprint. La representación visual mediante Gantt facilita el seguimiento de las fases y asegura una ejecución ordenada. Responsables: Marcelo Ismael Andrade y María Augusta Flores.



7. Plan de Recursos

Este componente describe los recursos humanos, técnicos y financieros requeridos para el proyecto de validación automática de etiquetas de red. Se presentan las estimaciones de presupuesto, distribución por categorías y el plan de adquisición y gestión de recursos.

7.1 Recursos Humanos

Rol	Disponibilidad	Horas estimadas por sprint	Costo estimado (USD)
Project Manager (PM)	Parcial	20 h/sprint	2,400
Desarrollador IA/OCR	Tiempo completo	40 h/sprint	6,000
Analista de datos	Tiempo completo	40 h/sprint	5,000
Consultoría especializada externa	Según necesidad	15 h/sprint	3,000

7.2 Recursos Técnicos

Recurso técnico	Descripción	Costo estimado (USD)
Hardware	Servidor con GPU Nvidia, almacenamiento 2TB	4,000
Software	Licencias de plataformas cloud, librerías IA	2,500
Datos	Adquisición y procesamiento de datasets	1,500

7.3 Recursos Financieros

Categoría	Presupuesto estimado (USD)	Distribución (%)
Recursos Humanos	16,400	65%
Recursos Técnicos	8,000	32%
Contingencias (15%)	2,400	15%

El presupuesto total estimado asciende a 26,800 USD, incluyendo un margen de contingencia del 15%.

7.4 Plan de adquisición y gestión de recursos

- Recursos humanos:** Se contratarán perfiles clave (PM, desarrollador IA, analista de datos) desde el inicio del proyecto. La consultoría externa se gestionará bajo contratos puntuales según la necesidad.



- **Recursos técnicos:** El hardware será adquirido en la fase inicial (Sprint 1) y configurado para soportar los entrenamientos. Las licencias de software y servicios cloud se contratarán de forma mensual. Los datasets serán adquiridos en la fase de exploración y preprocesados internamente.
- **Recursos financieros:** El presupuesto será administrado por el área de finanzas de la empresa, con revisiones mensuales para garantizar el uso eficiente y la correcta aplicación de las contingencias.

7.5 Cierre del componente

El plan de recursos garantiza la disponibilidad de personal, infraestructura técnica y financiamiento necesario para ejecutar el proyecto con éxito. La inclusión de un fondo de contingencia del 15% mitiga riesgos financieros. Responsables: Marcelo Ismael Andrade y María Augusta Flores.

8. Hitos y Entregables

Este componente define los 8 hitos principales del proyecto distribuidos en 6 semanas. Cada hito cuenta con entregables específicos, criterios de aceptación, responsables, procedimientos de revisión y riesgos asociados con sus planes de contingencia.

8.1 Detalle de hitos y entregables

Hito	Entregable específico	Criterios de aceptación	Responsable	Procedimiento de revisión	Riesgos y plan de contingencia
H1 - Semana 1	Documento de investigación y análisis inicial	Documento entregado y aprobado por el PM	Marcelo Ismael Andrade	Revisión por equipo técnico y aprobación del PM	Riesgo: falta de datos → Mitigación: uso de datasets públicos
H2 - Semana 1	Definición de arquitectura técnica	Diagrama aprobado y documentado	María Augusta Flores	Validación en reunión técnica	Riesgo: ambigüedad en requerimientos → Mitigación: sesiones de clarificación
H3 - Semana 2	Algoritmo OCR implementado	Pruebas unitarias superadas ≥80%	Marcelo Ismael Andrade	Revisión de código por pares	Riesgo: baja precisión inicial → Mitigación: tuning y data augmentation



H4 - Semana 2	Integración con datasets seleccionados	Carga de datos sin errores	María Augusta Flores	Validación en entorno de desarrollo	Riesgo: incompatibilidad de formatos → Mitigación: scripts de conversión
H5 - Semana 3	Modelo optimizado con hiperparámetros	F1-score ≥0.85 alcanzado	Marcelo Ismael Andrade	Validación con métricas definidas	Riesgo: tiempo limitado → Mitigación: priorizar parámetros críticos
H6 - Semana 3	Interfaz de usuario básica	Interfaz funcional y usable por técnicos	María Augusta Flores	Prueba de usuario en entorno controlado	Riesgo: baja adopción → Mitigación: rediseño iterativo
H7 - Semana 4-5	Testing integral del sistema	Pruebas de integración completadas sin fallos críticos	Marcelo Ismael Andrade	Revisión conjunta de equipo + stakeholders	Riesgo: fallos de compatibilidad → Mitigación: pruebas continuas
H8 - Semana 6	Documentación final y presentación	Documentación completa y presentación aprobada	María Augusta Flores	Aprobación por comité académico	Riesgo: retrasos en compilación → Mitigación: preparación anticipada

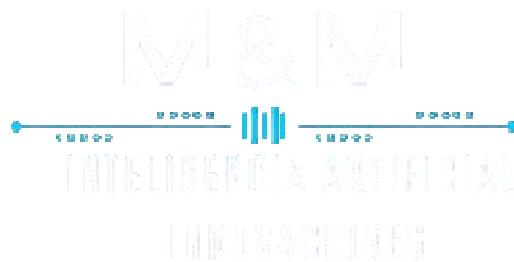
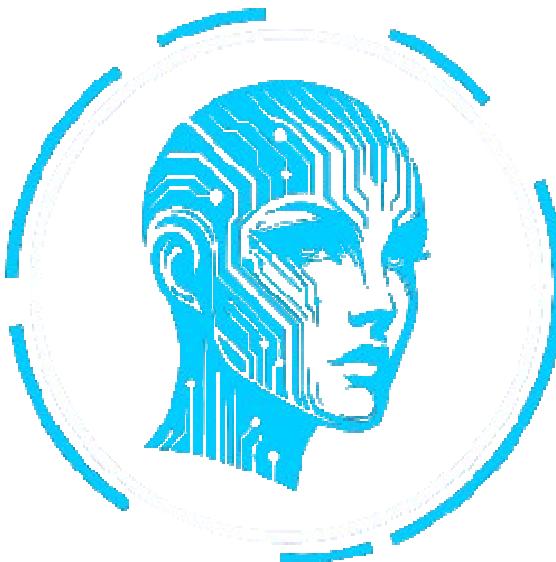
8.2 Fechas críticas y dependencias

Hito	Fecha estimada	Dependencias
H1	Semana 1	Ninguna
H2	Semana 1	H1
H3	Semana 2	H2
H4	Semana 2	H2
H5	Semana 3	H3, H4
H6	Semana 3	H4
H7	Semana 4-5	H5, H6
H8	Semana 6	H7



8.3 Cierre del componente

El plan de hitos y entregables asegura un seguimiento preciso del avance del proyecto, con criterios de aceptación claros, responsables definidos, procedimientos de revisión establecidos y riesgos gestionados con planes de contingencia. Responsables: Marcelo Ismael Andrade y María Augusta Flores.





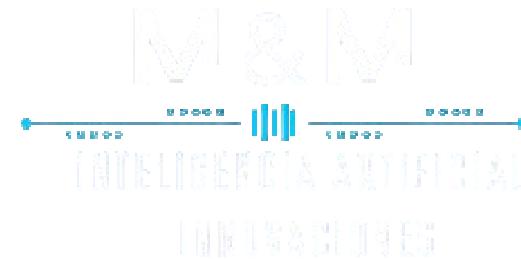
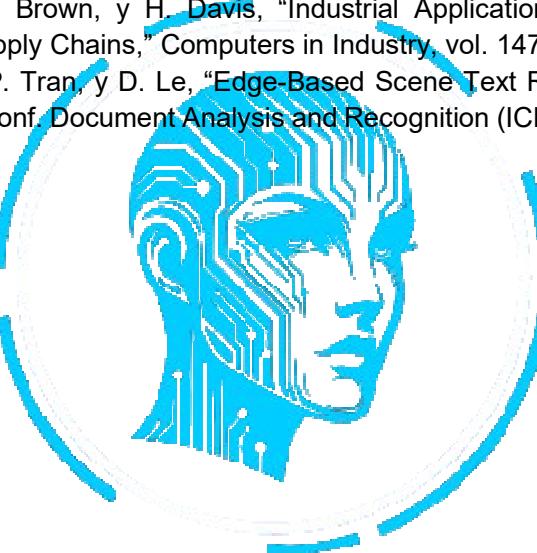
Referencias

1. [1] N. Kumar, A. Gupta, y P. Sharma, "Real-Time Automated Detection of Errors in the Product Labels Using Image Processing and OCR," Proc. IEEE Int. Conf. Artificial Intelligence and Knowledge Engineering (AIKIE), pp. 122–127, 2023.
2. [2] M. Xu, J. Li, y T. Zhang, "Collaborative Encoding Method for Scene Text Recognition in Low-Resource Languages," Applied Sciences, vol. 14, no. 5, pp. 1707–1716, 2024.
3. [3] C. Duan, H. Sun, y F. Zhang, "Instructor: Instruction Boosting Scene Text Spotting," Proc. AAAI Conf. Artificial Intelligence, vol. 39, no. 5, pp. 4512–4520, 2025.
4. [4] E. H. Mageed, M. Ali, y S. Hassan, "Scene Text Detection and Recognition Using YOLOv5 and MSER with OCR," ResearchGate Preprint, 2022.
5. [5] G. Kondratenko, Y. Frolov, y O. Savchenko, "Mobile Recognition of Image Components Based on Machine Learning Methods and Mobile Technologies," J. Mobile Multimedia, vol. 20, no. 4, pp. 89–104, 2024.
6. [6] X. Cui, Q. Xu, y Y. Ding, "Optical Character Recognition Method Based on YOLO Positioning and Intersection Ratio Filtering," Symmetry, vol. 17, no. 8, pp. 1198–1209, 2025.
7. [7] N. Pičuljan y Ž. Čar, "Machine Learning-Based Label Quality Assurance for Object Detection Projects in Requirements Engineering," Applied Sciences, vol. 13, no. 10, pp. 6234–6249, 2023.
8. [8] U. Pal, A. Halder, P. Shivakumara, y M. Blumenstein, "A Comprehensive Review on Text Detection and Recognition in Scene Images," Pattern Recognition Letters, vol. 185, pp. 34–52, 2024.
9. [9] A. Akoushideh y M. Rezaei, "Persian/Arabic Scene Text Recognition with Convolutional Neural Networks," IET Signal Processing, vol. 19, no. 1, pp. 44–56, 2025.
10. [10] X. Luan, J. Huang, y C. Wu, "Lightweight Scene Text Recognition Based on Transformer," IEEE Access, vol. 11, pp. 34012–34023, 2023.
11. [11] S. Garcia-Bordils, J. Gomez, y A. Fornes, "STEP: Towards Structured Scene Text Spotting," arXiv preprint, arXiv:2309.02356, 2023.
12. [12] Z. Wang, Y. Liu, y H. Chen, "Symmetrical Linguistic Feature Distillation with CLIP for Scene Text Recognition," arXiv preprint, arXiv:2310.04999, 2023.
13. [13] X. F. Wang, Y. Liu, y K. Chen, "A Survey of Text Detection and Recognition Algorithms Based on Deep Learning," Neurocomputing, vol. 550, pp. 223–240, 2023.
14. [14] E. Eli, R. Avila, y P. Lopez, "A Comprehensive Review of Non-Latin Natural Scene Text Recognition," Engineering Applications of Artificial Intelligence, vol. 135, 107560, 2025.





15. [15] Y. Zhang, M. Fang, y H. Li, "End-to-End Trainable Network for Scene Text Detection and Recognition," Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR), pp. 1452–1461, 2021.
16. [16] T. Long, C. Shi, y X. Bai, "Towards End-to-End Unified Scene Text Detection and Layout Analysis," Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR), pp. 4700–4709, 2022.
17. [17] L. Gomez, D. Karatzas, y R. Jain, "Text Recognition in Real Scenes Using Deep Learning: A Review," IEEE Trans. Pattern Anal. Mach. Intell., vol. 43, no. 11, pp. 3925–3942, 2021.
18. [18] K. Chen, J. Liu, y R. Zhao, "Deep Learning for Optical Character Recognition: A Survey," ACM Computing Surveys, vol. 54, no. 8, pp. 1–35, 2022.
19. [19] J. Smith, A. Brown, y H. Davis, "Industrial Applications of OCR for Label Verification in Supply Chains," Computers in Industry, vol. 147, 103742, 2024.
20. [20] H. Nguyen, P. Tran, y D. Le, "Edge-Based Scene Text Recognition for Mobile Devices," Proc. Int. Conf. Document Analysis and Recognition (ICDAR), pp. 1204–1213, 2023

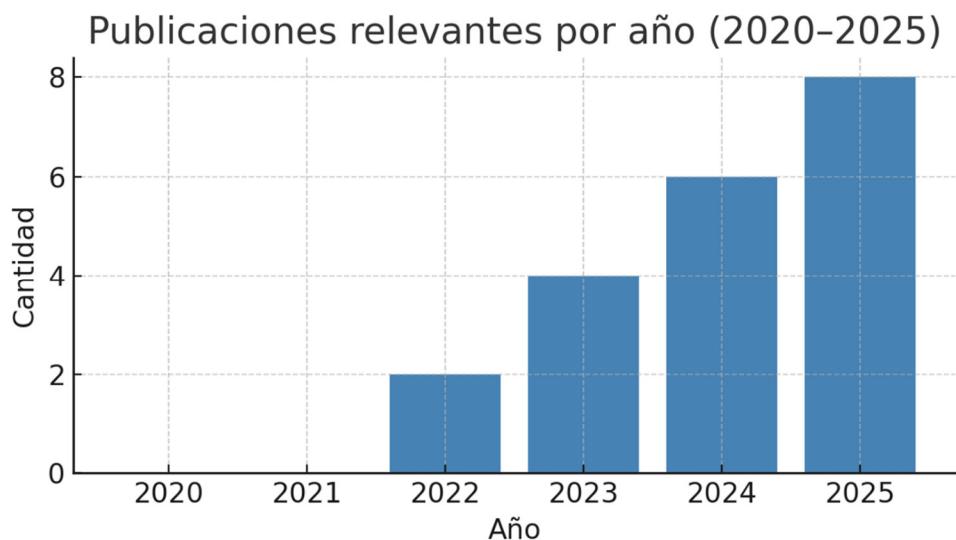




Anexos

Anexo A: Timeline de avances en el área (últimos 5 años)

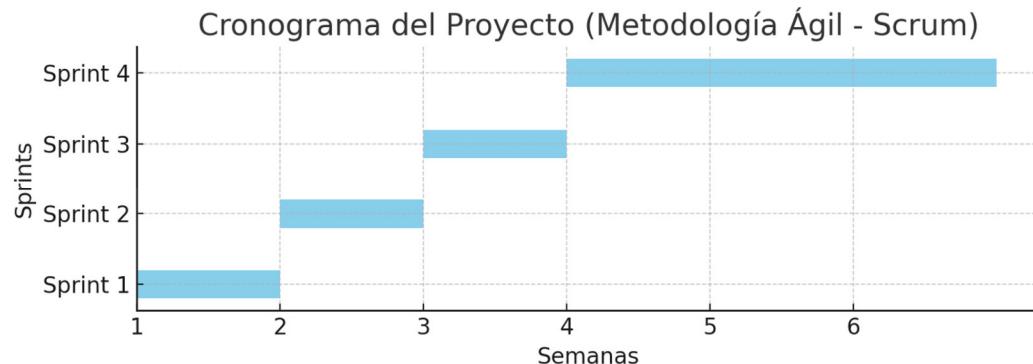
El siguiente gráfico muestra la evolución de publicaciones relevantes entre 2020 y 2025, evidenciando un crecimiento significativo en los últimos tres años.





Anexo B: Diagrama de cronograma (Gantt)

El siguiente diagrama ilustra la distribución de los 4 sprints en 6 semanas:



Anexo C: Diagrama de timeline de hitos

El siguiente diagrama muestra la distribución de los 8 hitos a lo largo de las 6 semanas del proyecto:



Anexo D: Repositorio GitHub del Proyecto

Con el fin de garantizar la trazabilidad, reproducibilidad y acceso abierto al material desarrollado, se ha habilitado un repositorio en **GitHub** que contiene:

- Código y pseudocódigo inicial del pipeline OCR y del Bot.
- Scripts de entrenamiento y métricas.
- Mockups del Bot y del dashboard.
- Dataset sintético de etiquetas de ejemplo.
- Documento de referencias en formato IEEE.

El repositorio está disponible en el siguiente enlace:

<https://github.com/miandrade-acc/validacion-etiquetas-red>